

İK ÇALIŞAN İSTİFA (CHURN) TAHMİNİ

CRISP-DM Metodolojisi Danışmanlık ve Model Değerlendirme Raporu

1. Yönetici Özeti

Bu rapor, şirketin İnsan Kaynakları (İK) departmanı için çalışanların istifa etme olasılıklarını tahmin etmek amacıyla geliştirilen makine öğrenmesi modelinin bulgularını sunar. Projenin ana hedefi, kritik çalışanlar şirketi terk etmeden önce İK departmanına erken müdahale imkanı sunarak, yeni işe alım ve onboarding maliyetlerini azaltmaktır.

Yapılan finansal simülasyonlara göre, model tabanlı erken elde tutma eylemlerine geçilmesi durumunda, şirketin işgücü kaybından elde edeceği varsayılan net tasarruf \$1,503,000.00 (eşik = 0.50) olarak hesaplanmıştır. Ancak, karar eşik değeri (threshold) optimize edilerek 0.10 seviyesine düşürüldüğünde, Net Yıllık Tasarruf \$1,872,000.00 seviyesine maksimize edilmektedir. Bu optimizasyon, şirkete ek olarak \$369,000.00 daha tasarruf sağlamaktadır. Modelsiz süreçte toplam işten ayrılma kaybı \$4,590,000.00 iken, optimum model destekli yönetim maliyeti \$2,718,000.00 seviyesine düşürülmüştür.

2. Veri Yapısı ve Sızıntı (Data Leakage) Önleme

Veri kümesinde toplam 49,653 satır analiz edilmiştir. İstifa eden çalışanların oranı %3 seviyesinde olduğundan, veri kümesinde yüksek derecede sınıf dengesizliği (class imbalance) mevcuttur. Bunun yanı sıra, veri kümesi her çalışanın yıllara göre kaydını barındıran panel veri yapısındadır. Yapılan gelişmiş istatistiksel testlerde (T-Testi ve Ki-Kare testi), yaş farkı (p-değeri < 0.0001), kıdem süresi farkı (p-değeri < 0.0001), iş birimi dağılımı (p-değeri < 0.0001) ve cinsiyet dağılımının (p-değeri < 0.0001) istifa kararı üzerinde istatistiksel olarak son derece anlamlı ve belirleyici olduğu bilimsel olarak kanıtlanmıştır.


Kritik Güvenlik Adımı: Veri sızıntısını (Data Leakage) engellemek amacıyla, aynı çalışanın farklı yıllardaki kayıtlarının hem eğitim hem de test kümesine dağılması engellenmiştir. Bu amaçla split işlemi çalışan ID'si bazında (GroupShuffleSplit) yapılmış ve tüm preprocessing (OneHot, StandardScaler) fit adımları sadece train kümesi üzerinde yürütülmüştür.

3. Model Performans ve Karşılaştırma Sonuçları

Aynı veri bölümlenmesi ve 5-katlı GroupKFold çapraz doğrulama yapısı kullanılarak 10 farklı makine öğrenmesi modeli yarışdırılmıştır. En başarılı sonuçları veren algoritma Gradient Boosting olmuştur. Modellerin başarı sonuçları aşağıdaki tabloda sunulmuştur:

Model	Test Acc	Precision	Recall	F1-Score	ROC-AUC
Gradient Boosting	0.987	0.950	0.618	0.749	0.932
Random Forest	0.975	0.576	0.729	0.644	0.912


Hist Gradient Boosting	0.971	0.513	0.850	0.640	0.935
Decision Tree	0.962	0.435	0.788	0.560	0.888
AdaBoost	0.980	0.991	0.366	0.535	0.895
Extra Trees	0.961	0.418	0.709	0.526	0.895
K-Nearest Neighbors	0.976	0.715	0.369	0.487	0.837



4. Hata Matrisi (Confusion Matrix) ve Karar Destek Karşılığı


Seçilen en iyi modelin test setindeki hata dağılımları şöyledir:

- True Negatives (TN): 9,610 çalışan doğru şekilde kalacak olarak tahmin edildi.
- True Positives (TP): 170 çalışan doğru şekilde istifa riskiyle tespit edildi. İK bu kişilere önceden müdahale edebilir.
- False Positives (FP): 9 çalışan istifa edecek dendi ancak ayrılmadı. (İK'nın gereksiz elde tutma bütçe harcaması)
- False Negatives (FN): 136 çalışan kalacak dendi ama istifa etti. (En yüksek maliyetli hatalı tahmin)



5. Öznitelik Önem Düzeyleri (Feature Importance)

Modelin istifa kararını alırken en çok ağırlık verdiği çalışan öznitelikleri aşağıda listelenmiştir. Bu grafik, İK'nın hangi alanlara odaklanması gerektiğini gösterir:




5b. Karar Eşiği Optimizasyonu (Threshold Tuning)

Çalışan kaybı tahminlerinde istifa edecek personeli kaçırmak (False Negative), yanlış alarm oranla çok daha yüksek maliyetlidir (\$15,000 vs \$3,000). Bu nedenle olasılık karar eşiği varsayılan 0.50 yerine 0.10 seviyesine indirilmiştir. Bu ayarlamayla test setindeki hata matrisi şu şekilde güncellenmiştir:



- True Negatives (TN): 9,562 çalışan.
- True Positives (TP): 227 çalışan (Müdahale imkanı 170'ten 227 kişiye çıkmıştır).
- False Positives (FP): 57 çalışan (Gereksiz elde tutma bütçe harcaması).
- False Negatives (FN): 79 çalışan (Kaçırılan kayıp, 136'dan 79'e indirilmiştir).

Eşik değerinin optimizasyon süreci aşağıdaki grafikte gösterilmiştir. Bu sayede şirket \$1,872,000 net tasarruf sağlar.



6. İş Analitiği ve İstifa Davranışları

Departman bazlı istifa oranları ve kıdem yılına göre istifa eğilimleri analiz edilmiş ve en yüksek risk altındaki çalışan grupları belirlenmiştir:



7. İK Departmanı Stratejik Yol Haritası

İstifa risklerinin önlenmesi amacıyla model sonuçlarının operasyonel sürece entegrasyonu için şu adımların izlenmesi önerilir:

- **Yüksek Riskli Gruplara Öncelikli Aksiyon:** İstifa olasılığı %80'in üzerinde olan çalışanlar için acilen departman müdürleri liderliğinde 1-1 kariyer görüşmeleri yapılmalıdır.
- **Elde Tutma Bütçesinin Optimize Edilmesi:** Rastgele dağıtılan bonuslar yerine, modelin yüksek risk gördüğü çalışanlar üzerinde 3,000 USD bütçe limitli prim, rotasyon veya unvan iyileştirmesi odaklanmalıdır.

- Model Sınırlılıkları ve İzleme: Modelin tahminleri yeni verilerle düzenli olarak güncellenmelidir. Yılda en az 1 kez modelin yeni İK verileriyle yeniden eğitilmesi (retraining) tavsiye edilir.